To [4].	k-최근접 이웃 회귀         • 지도 학습 알고리즘은 크게 분류와 회귀로 나뉨         • 회귀: 클래스 중 하나로 분류하는 것이 아니라 임의의 어떤 숫자를 예측하는 문제, 두 변수 사이의 상관관계를 분석하는 방법\
in [i]:	# 데이터 준비 import numpy as np perch_length = np.array([8.4, 13.7, 15.0, 16.2, 17.4, 18.0, 18.7, 19.0, 19.6, 20.0, 21.0,
In [2]:	115.0, 125.0, 130.0, 120.0, 120.0, 130.0, 135.0, 110.0, 130.0, 150.0, 150.0, 145.0, 150.0, 145.0, 170.0, 225.0, 145.0, 188.0, 180.0, 197.0, 218.0, 300.0, 260.0, 265.0, 250.0, 300.0, 320.0, 514.0, 556.0, 840.0, 685.0, 700.0, 700.0, 690.0, 900.0, 650.0, 820.0, 850.0, 900.0, 1015.0, 820.0, 1100.0, 1000.0, 1000.0, 1000.0, 1000.0])
	<pre>plt.scatter(perch_length, perch_weight) plt.xlabel("length") plt.ylabel("weight") plt.show()</pre>
	800 -
	400 - 200 - 0 -
In [3]:	10 15 20 25 30 35 40 45 length  from sklearn.model_selection import train_test_split
In [4]: In [5]:	train_input, test_input, train_target, test_target = train_test_split(perch_length, perch_weight, random_state=42)  train_input=train_input.reshape(-1,1) # reshape의 -1은 나머지 원소 개수로 모두 채우겠다는 의미임 test_input=test_input.reshape(-1,1) # (14,1)도 똑같은 값임 print(train_input.shape, test_input.shape)  (42, 1) (14, 1)  from sklearn.neighbors import KNeighborsRegressor
111 [5].	knr=KNeighborsRegressor() knr.fit(train_input,train_target) print(knr.score(test_input,test_target)) # 이건 결정계수임 <-> 정확도 0.992809406101064
In [6]:	결정 계수(R^2)         • 결정계수: $1 - (sum((타깃 - 예측)^2)/sum((타깃 - 평균)^2)$ • 타깃의 평균 정도를 예측하는 수준이라면 결정 계수는 0에 가까워지고, 예측이 타깃에 가가워지면 결정 계수가 1에 가까워진다         # 결정 계수말고 다른 값으로 직접 모델이 얼마나 좋은지 이해해보기         from sklearn.metrics import mean_absolute_error
	# 테스트 세트에 대한 예측을 만듬 test_prediction=knr.predict(test_input)  # 테스트 세트에 대한 평균 절댓값 오차 계산 mae=mean_absolute_error(test_target, test_prediction) print(mae)  19.157142857142862
	과대 적합 VS 과소 적합  ■ 과대 적합: 훈련 세트에서 점수가 굉장히 좋았지만, 테스트 세트에서는 점수가 굉장히 나쁜 경우  ■ 과소 적합: 훈련 세트보다 테스트 세트의 점수가 높거나 두 점수가 모두 너무 낮은 경우  ■ 모델이 너무 단순하여 훈련 세트에 적절히 훈련되지 않은 경우  ■ 훈련 세트가 전체 데이터를 대표하지 못한 경우
In [7]: In [8]:	■ 훈련 세트와 테스트 세트의 크기가 매우 작은 경우 ■ k-최근접 이웃 알고리즘에서 k를 낮추는 방식으로 해결할 수 있음. 이는 국지적인 패턴에 민감해지도록 하기 위함  print(knr.score(train_input, train_target)) 0.9698823289099254  knr.n_neighbors=3
	knr.fit(train_input, train_target) print(knr.score(train_input, train_target)) print(knr.score(test_input, test_target))  0.9804899950518966 0.9746459963987609
	선형 회귀  k-최근접 이웃의 한계  • 새로운 샘플이 훈련 세트의 범위를 벗어나면 엉뚱한 값을 예측할 수 있음
In [9]:	<pre>perch_length = np.array([8.4, 13.7, 15.0, 16.2, 17.4, 18.0, 18.7, 19.0, 19.6, 20.0, 21.0,</pre>
In [10]:	218.0, 300.0, 260.0, 265.0, 250.0, 300.0, 320.0, 514.0, 556.0, 840.0, 685.0, 700.0, 700.0, 690.0, 900.0, 650.0, 820.0, 850.0, 900.0, 1015.0, 820.0, 1100.0, 1000.0, 1000.0, 1000.0])  from sklearn.model_selection import train_test_split  train_input, test_input, train_target, test_target=train_test_split(perch_length, perch_weight, random_state=42)
In [11]: In [12]:	<pre>train_input=train_input.reshape(-1,1) test_input=test_input.reshape(-1,1)  from sklearn.neighbors import KNeighborsRegressor knr=KNeighborsRegressor(n_neighbors=3)</pre>
In [13]:	<pre>knr.fit(train_input, train_target) print(knr.predict([[50]])) [1033.3333333]  import matplotlib.pyplot as plt distances, indexes=knr.kneighbors([[50]])</pre>
	<pre>plt.scatter(train_input, train_target) plt.scatter(train_input[indexes], train_target[indexes], marker="D") plt.scatter(50, 1033, marker="A") plt.xlabel("length") plt.ylabel("weight") plt.ylabel("weight")</pre>
	1000 -
	800 - 400 - 400 -
	200 - 15 20 25 30 35 40 45 50
In [14]: In [15]:	<pre>length  print(np.mean(train_target[indexes]))  1033.3333333333333333  print(knr.predict([[100]]))</pre>
In [16]:	# 100cm 농어의 이웃 distances,indexes=knr.kneighbors([[100]]) plt.scatter(train_input,train_target) plt.scatter(train_input[indexes],train_target[indexes],marker="D") plt.scatter(100 knr.predict([[100]]) marker="D")
	plt.scatter(100, knr.predict([[100]]), marker="^") plt.show()  1000 -
	800 -
	200 -
In [17]:	선형 회귀 from sklearn.linear_model import LinearRegression
In [18]:	lr=LinearRegression() lr.fit(train_input,train_target) print(lr.predict([[50]])) [1241.83860323] print(lr.coef_,lr.intercept_) # coef_와 intercept_ 속성은 기울기(각 항의 계수)와 y절편을 뜻함
In [19]:	[39.01714496] -709.0186449535474  plt.scatter(train_input,train_target)  plt.plot([15,50],[15*lr.coef_+lr.intercept_,50*lr.coef_+lr.intercept_])  plt.scatter(50,1241.8,marker="^")  plt.xlabel("length")
	plt.ylabel("weight") plt.show()  1200 - 1000 -
	800 - 400 - 400 -
	200 -
In [20]:	15 20 25 30 35 40 45 50  length  print(lr.score(train_input, train_target)) print(lr.score(test_input, test_target))  0.9398463339976041 0.824750312331356
In [21]:	다항 회귀  • 2차 방정식의 그래프를 그리려면 길이를 제곱한 항이 훈련 세트에 추가되어야 함  train_poly=np.column_stack((train_input**2, train_input)) test_poly=np.column_stack((test_input**2, test_input))
In [22]:	<pre>print(train_poly.shape, test_poly.shape)  (42, 2) (14, 2)  lr=LinearRegression() lr.fit(train_poly, train_target)  print(lr.predict([[50**2,50]]))  [1573.98423528]</pre>
In [23]: In [24]:	<pre>print(lr.coef_,lr.intercept_) [ 1.01433211 -21.55792498] 116.05021078278264  point=np.arange(15,50) plt.scatter(train_input,train_target)</pre>
	plt.plot(point,1.01*point**2-21.6*point+116.05)  plt.scatter(50,1574,marker="^") plt.show()  1600 -
	1200 - 1000 - 800 -
	600 - 400 - 200 -
In [25]:	15 20 25 30 35 40 45 50  print(lr.score(train_poly, train_target)) print(lr.score(test_poly, test_target))  0.9706807451768623 0.9775935108325122
	특성 공학과 규제         다중 회귀         • 다중 회귀: 여러 개의 특성을 사용한 선형 회귀 -> 직선이 아닌 평면으로 학습         도보고 한 보고 있는 보고 있는 보고 있는 보고 있다.
In [26]:	• 특성 공학: 기존의 특성을 사용해 새로운 특성을 뽑아내는 작업  import pandas as pd df=pd.read_csv("perch_full.csv") perch_full=df.to_numpy() print(perch_full)  [[ 8.4
	[15.
	[21. 5.92 3.31] [21. 5.69 3.67] [21.3 6.38 3.53] [22. 6.11 3.41] [22. 5.64 3.52] [22. 6.11 3.52] [22. 5.88 3.52] [22. 5.88 3.52] [22. 5.88 3.52] [22. 5.88 3.62]
	[22.5       6.79       3.62]         [22.7       5.95       3.63]         [23.       5.22       3.63]         [23.5       6.28       3.72]         [24.       7.29       3.72]         [24.       6.38       3.82]         [24.6       6.73       4.17]         [25.       6.44       3.68]
	[25.6 6.56 4.24] [26.5 7.17 4.14] [27.3 8.32 5.14] [27.5 7.17 4.34] [27.5 7.05 4.34] [27.5 7.28 4.57] [28. 7.82 4.2 ] [28.7 7.59 4.64] [30. 7.62 4.77]
	[32.8
	[39. 12.43 7.35] [40. 11.93 7.11] [40. 11.73 7.22] [40. 12.38 7.46] [40. 11.14 6.63] [42. 12.8 6.87] [43. 11.93 7.28] [43. 12.51 7.42] [43. 5 12.6 8.14]
In [27]:	[43.5 12.6 8.14] [44. 12.49 7.6]]  perch_weight = np.array([5.9, 32.0, 40.0, 51.5, 70.0, 100.0, 78.0, 80.0, 85.0, 110.0,
In [28]: In [29]:	train_input, test_input, train_target, test_target=train_test_split(perch_full, perch_weight, random_state=42)  from sklearn.preprocessing import PolynomialFeatures # polynomialfeatures 클래스는 변환기로서, 각 특성을 제곱한 항을 추가하고 특성끼리 서로 곱한 항을 추가함 poly=PolynomialFeatures(include_bias=False) # include_bias는 선형 방정식의 절편에 1인 특성이 곱해지는 계수라고 볼 수 있음 poly.fit([[2,3]])
In [30]:	<pre>poly.fit([[2,3]]) print(poly.transform([[2,3]]))  [[2. 3. 4. 6. 9.]]  poly = PolynomialFeatures(include_bias=False) poly.fit(train_input) train_poly = poly.transform(train_input) print(train_poly.shape)  (42, 9)</pre>
In [31]: Out[31]: In [32]:	<pre>poly.get_feature_names_out() array(['x0', 'x1', 'x2', 'x0^2', 'x0 x1', 'x0 x2', 'x1^2', 'x1 x2',</pre>
In [33]:	from sklearn.linear_model import LinearRegression lr=LinearRegression() lr.fit(train_poly, train_target) print(lr.score(train_poly, train_target)) print(lr.score(test_poly, test_target)) 0.9903183436982124 0.9714559911594145  poly=PolynomialFeatures(degree=5_include_bias=False) # bias_M7/H64= 73550
In [34]:	poly=PolynomialFeatures(degree=5,include_bias=False) # bias 매개변수는 고차항의 최대 차수를 지정함 poly.fit(train_input) train_poly=poly.transform(train_input) test_poly=poly.transform(test_input) print(train_poly.shape)  (42, 55)  lr.fit(train_poly,train_target) print(lr.score(train_poly,train_target))
	print(lr.score(train_poly, train_target)) print(lr.score(test_poly, test_target)) # 과대 적합 됨  0.9999999999996176 -144.40585108215134  규제  • 규제: 머신러닝 모델이 훈련 세트를 너무 과도하게 학습하지 못하도록 훼방하는 것-> 과대적합 방지, 선형 회귀의 계수의 크기를 작게 만듬
In [36]:	<ul> <li>렛지: 계수를 제곱한 값을 기준으로 규제를 적용, alpha 값이 클 수록 규제 강도가 세짐</li> <li>라쏘: 계수의 절댓값을 기준으로 규제를 적용</li> <li># 정규화하기</li> <li>from sklearn.preprocessing import StandardScaler ss=StandardScaler() ss.fit(train_poly) train_scaled=ss.transform(train_poly)</li> </ul>
In [37]:	
In [38]:	<pre>0.9896101671037343 0.9790693977615379  import matplotlib.pyplot as plt train_score=[] test_score=[] alpha_list=[0.001,0.01,0.1,1,10,100]</pre>
In [39]:	<pre>for alpha in alpha_list:     ridge=Ridge(alpha=alpha)     ridge.fit(train_scaled,train_target)     train_score.append(ridge.score(train_scaled,train_target))     test_score.append(ridge.score(test_scaled,test_target))</pre> plt.plot(np.log10(alpha_list),train_score) plt.plot(np.log10(alpha_list),test_score) plt.xlabel("alpha")
	plt.ylabel("R^2") plt.show()  0.990
	0.985 - 0.980 - \$\frac{\gamma}{2} \ 0.975 -
	0.965 - 0.960 -
In [40]:	ridge=Ridge(alpha=0.1) ridge.fit(train_scaled, train_target) print(ridge.score(train_scaled, train_target)) print(ridge.score(test_scaled, test_target))
In [41]:	print(ridge.score(test_scaled,test_target)) 0.9903815817570368 0.9827976465386983  # 라쏘 회귀 from sklearn.linear_model import Lasso lasso=Lasso() lasso.fit(train_scaled,train_target) print(lasso.score(train_scaled,train_target))
In [42]:	<pre>print(lasso.score(train_scaled, train_target)) print(lasso.score(test_scaled, test_target))  0.989789897208096 0.9800593698421884  train_score=[] test_score=[] alpha_list=[0.001,0.01,0.1,1,10,100]</pre>
	<pre>for alpha in alpha_list:     lasso=Lasso(alpha=alpha,max_iter=10000)     lasso.fit(train_scaled,train_target)     train_score.append(lasso.score(train_scaled,train_target))     test_score.append(lasso.score(test_scaled,test_target))  C:\Users\82106\anaconda3\lib\site-packages\sklearn\linear_model\_coordinate_descent.py:631: ConvergenceWarning: Objective did not converge. You might want to increase the number of iterations, check the scale of the features or consider increasing regularisation. Duality gap: 1.878e+04, tolerance: 5.183e+02     model = cd_fast.enet_coordinate_descent(</pre>
In [43]:	
	0.96 -
	₹ 2 2 0.94 -
	R \ 2
In [44]:	0.94 - 0.92 0 1 2